Ciência de Dados
Relatório II

Guilherme Martins Soares - 00217055
Natália Capra Ferrazzo - 00243977
Rafael Corrêa de Lima - 00266206
Março de 2022

1. Análise de Dados

O dataset disponibilizado para estudo é um arquivo .csv que possui tem 100 medidas (linhas) de 8 preditores (as primeiras oito colunas, "x1...x8") e os resultados da medida da resposta (última coluna "y"). Estes dados foram gerados por simulação e portanto existe uma relação pre-estabelecida que pode ser capturada por regressão linear.

```
#importando bibliotecas necessárias
import os
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
from pathlib import Path
np.random.seed(42)
```

A primeira etapa a ser feita é a importação e visualização do dataset. Esta etapa é importante para assegurar-se de que a sintaxe de importação está correta e nenhum erro - por exemplo: de separação de colunas - foi cometido.

```
#atribuindo a "p" o caminho atual de trabalho.
p = os.getcwd()
#importando o dataset através da biblioteca Pandas
data = pd.read_csv(p + '/dados.csv', sep=',', index_col=(0))
#printando o dataset
data
```

	x1	x2	x3	x4	x5	x6	x7	x8	y
0	0.544883	0.437587	0.645894	0.563544	0.548814	0.423655	0.602763	0.715189	2.318601
1	0.791725	0.925597	0.568045	0.802868	0.891773	0.528895	0.383442	0.963663	2.294089
2	0.832620	0.978618	0.870012	0.836646	0.071036	0.778157	0.020218	0.087129	0.255917
3	0.118274	0.944669	0.143353	0.122540	0.799159	0.639921	0.780529	0.461479	2.445777
4	0.774234	0.018790	0.568434	0.785304	0.521848	0.456150	0.264556	0.414662	1.313699
...	...	...	...	...	...	...	...	...	...
95	0.713767	0.431760	0.399161	0.760395	0.399812	0.639187	0.344718	0.671383	1.763385
96	0.653421	0.110477	0.536923	0.673011	0.614528	0.726342	0.822407	0.070042	1.344047
97	0.029950	0.606308	0.109784	0.042059	0.405036	0.737254	0.321043	0.405374	2.055069
98	0.103298	0.534917	0.029190	0.115818	0.703217	0.867167	0.959142	0.634786	3.083833
99	0.190567	0.842777	0.518150	0.214737	0.404244	0.019123	0.365100	0.524184	2.459045

100 rows × 9 columns

Tabela 1: Dataset objeto de estudo corretamente importado

A seguir, uma tabela de correlação é gerada:

```
corr = data.corr()
corr
```

Índice	x1	x2	x3	x4	x5	x6	x7	x8	y
x1	1	-0.249202	0.0460718	0.99877	0.0747434	-0.0061617	-0.0821035	0.0706609	-0.472483
x2	-0.249202	1	-0.0288268	-0.251541	-0.00131288	0.149947	-0.0507491	0.127977	0.156587
x3	0.0460718	-0.0288268	1	0.048058	-0.0890607	0.248118	-0.0970147	-0.23455	-0.245265
x4	0.99877	-0.251541	0.048058	1	0.0770229	-0.0109875	-0.0880109	0.0770174	-0.47159
x5	0.0747434	-0.00131288	-0.0890607	0.0770229	1	-0.0745931	0.171763	0.0046632	0.0234954
x6	-0.0061617	0.149947	0.248118	-0.0109875	-0.0745931	1	0.145628	-0.0142194	0.0187871
x7	-0.0821035	-0.0507491	-0.0970147	-0.0880109	0.171763	0.145628	1	0.0405882	0.607263
x8	0.0706609	0.127977	-0.23455	0.0770174	0.0046632	-0.0142194	0.0405882	1	0.564683
y	-0.472483	0.156587	-0.245265	-0.47159	0.0234954	0.0187871	0.607263	0.564683	1

Tabela 2: Correlação entre as variáveis com heatmap associado

Com o auxílio do *heatmap*, a identificação de valores de correlações especiais é facilitada. Além disso, uma *matriz de dispersão* pode ser plotada para uma melhor visualização:

```
scatter_matrix(data, alpha=0.2, figsize=(8, 8), diagonal='kde')
```

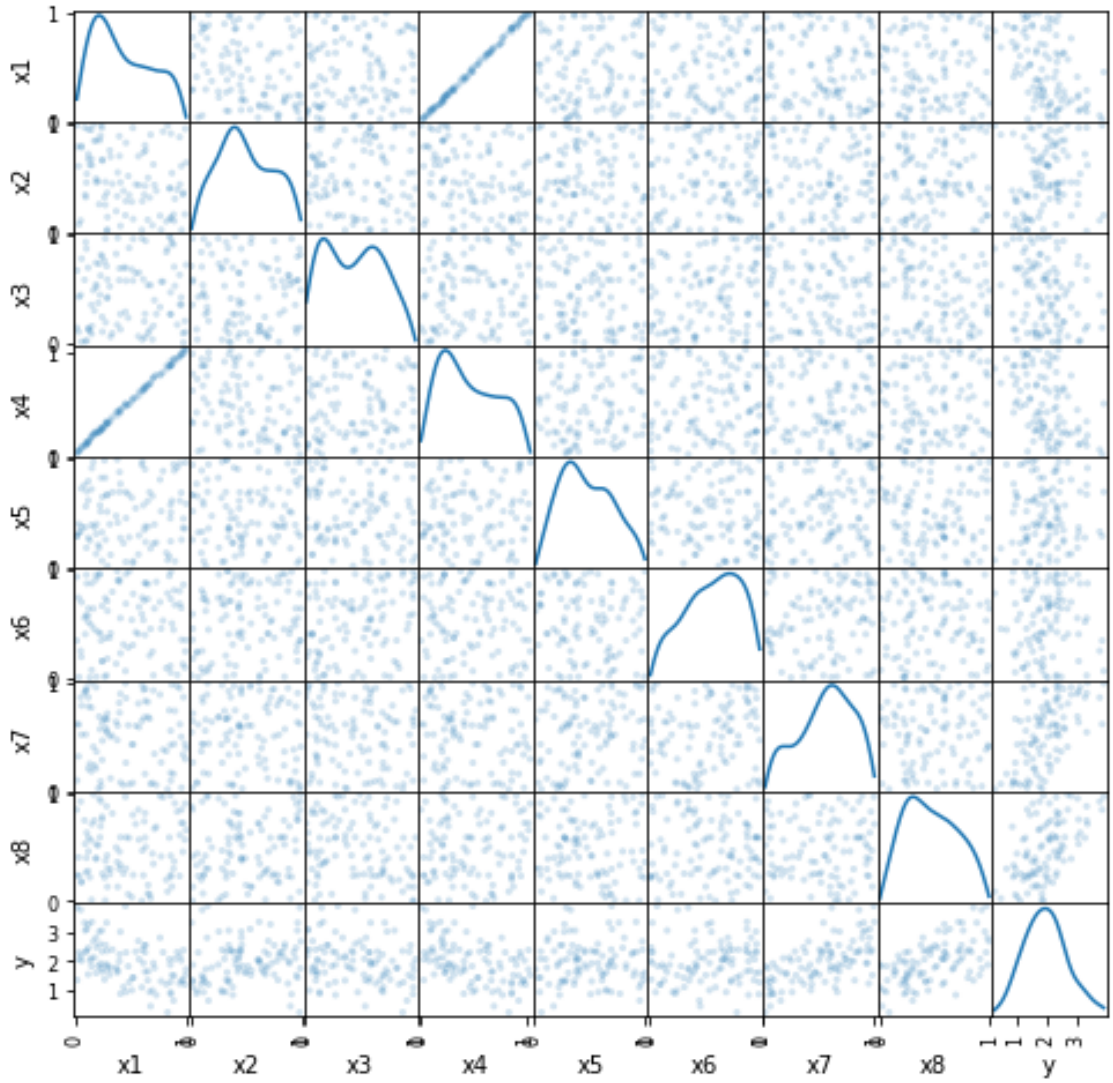

Gráfico 1: Matriz de Dispersão das variáveis

Nesta etapa, já é possível descartar uma variável:

> **x4**: Sua correlação com a variável *x1* é de aproximadamente 1, o que significa que elas são *colineares* e, portanto, uma delas deve ser descartada.

Em um primeiro momento, também pode-se imaginar que *x5* e *x6* devam ser descartadas, devido a sua baixa correlação com a variável *y*. Porém, antes de descartá-las, uma análise mais profunda de suas relações com as demais variáveis faz-se necessária:

x5 possui uma correlação mais alta com *x7*, e **x6** com *x3*, o que significa que é possível que haja uma relação de *sinergia* entre elas, o que aperfeiçoaria o modelo.

Sendo assim, nesta etapa apenas *x4* é descartada.

```
del(data['x4'])
```

2. Preparação dos Dados

Para que seja possível analisar se o modelo de regressão gerado possui um bom desempenho em dados ainda não coletados, é necessário ter um conjunto de dados separados, com o qual não se "alimentará" o algoritmo. Uma boa separação é 80/20: 80% dos dados são utilizados para treinar o modelo e 20% para testá-lo.

```
# splitting the data
train, test = train_test_split(data, test_size=0.2, shuffle=42)
```

3. Aplicando a Seleção Mista

Uma boa maneira de lidar com uma regressão de múltiplas variáveis preditoras é utilizando a *Seleção Mista*:

1. Começa-se com o procedimento *incremental* adicionando preditores ao conjunto de variáveis relevante: Considerando que inicialmente existem *p* preditores, faz-se *p* regressões simples e seleciona-se o preditor X_i com menor valor-p. Faz-se *p-1* regressões de 2 variáveis, combinando o preditor escolhido na etapa anterior com os outros, dois a dois. Seleciona-se o segundo preditor usando novamente o critério de menor valor-p.
2. Se notado que neste procedimento um preditor que inicialmente tinha um valor-p baixo (e por isto foi escolhido), passa a ter uma valor-p acima de um limite pré-estabelecido, ele é retirado do conjunto (o que equivale a um passo decremental.

3. Depois do passo *decremental*, continua-se com passos incrementais até um critério de parada.

Nessa etapa, 3 *arrays* são criados para auxiliar na implementação do algoritmo. O array *col* é para implementar os passos, indo de *x1* a *x8*, já desconsiderando a variável deletada *x4*. Já os arrays *result* e *y_predicted* armazenarão, respectivamente, o resultado da regressão linear (a equação da reta) e o *y* previsto pela implementação dessa regressão nos pontos de teste.

```
col = data.columns.drop('y')

result=[]
y_predicted = []
```

Agora, uma iteração passando por todas as variáveis é feita, seguindo a fórmula "y ~ col[i]", utilizando os dados de treinamento, provenientes do dataframe *train*. Após, o resultado é aplicado ao dataframe *test* e armazenado em *y_predicted*. Por fim, é printado na tela os coeficientes *c0* e *c1*, seguindo a fórmula $y \sim c1.x_i + c0$, e os valores do teste T de Student.

```
for i in range(len(data.columns)-1):
    result.append(sm.OLS.from_formula(formula= 'y ~ '+str(col[i]),
data=train).fit())
    y_predicted.append(result[i].predict(test))

    print(result[i].t_test(np.identity(2)))
```

Abaixo o *output* é mostrado:

```
                     Test for Constraints  (y ~ x1)
==============================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
c0          2.5396      0.134     18.956      0.000       2.273       2.806
c1         -1.2043      0.239     -5.042      0.000      -1.680      -0.729
==============================================================================
```

```
                     Test for Constraints  (y ~ x2)
==========================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
--------------------------------------------------------------------------
c0          1.8629      0.174     10.708      0.000       1.517       2.209
c1          0.2203      0.292      0.755      0.452      -0.360       0.801
==========================================================================


                     Test for Constraints  (y ~ x3)
==========================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
--------------------------------------------------------------------------
c0          2.2730      0.156     14.547      0.000       1.962       2.584
c1         -0.6491      0.291     -2.232      0.029      -1.228      -0.070
==========================================================================


                     Test for Constraints  (y ~ x5)
==========================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
--------------------------------------------------------------------------
c0          1.8204      0.179     10.184      0.000       1.465       2.176
c1          0.3188      0.319      0.999      0.321      -0.316       0.954
==========================================================================


                     Test for Constraints  (y ~ x6)
==========================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
--------------------------------------------------------------------------
c0          1.9481      0.171     11.402      0.000       1.608       2.288
c1          0.0554      0.279      0.199      0.843      -0.499       0.610
==========================================================================
```

```
                     Test for Constraints  (y ~ x7)
==========================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
--------------------------------------------------------------------------
c0         1.1110      0.127      8.763      0.000       0.859       1.363
c1         1.6932      0.214      7.907      0.000       1.267       2.120
==========================================================================


                     Test for Constraints  (y ~ x8)
==========================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
--------------------------------------------------------------------------
c0         1.2543      0.147      8.539      0.000       0.962       1.547
c1         1.4364      0.254      5.650      0.000       0.930       1.943
==========================================================================
```

Seguindo o algoritmo de seleção mista, escolhe-se os preditores cujo *p-value* é menor. Nesse caso, *x1*, *x7* e *x8*. Escolhe-se *x1* e a regressão linear é feita novamente, desta vez seguindo a fórmula $y \sim c1.x_1 + c2.x_i + c0$

```
for i in range(1, len(data.columns)-1):
    formula = 'y ~ x1 + '+str(col[i])
    result.append(sm.OLS.from_formula(formula = formula,
data=train).fit())
    y_predicted.append(result[i-1].predict(test))
    print(formula)
    print(result[i-1].t_test(np.identity(3)))
```

O output gerado fica:

```
                     Test for Constraints  (y ~ x1 + x2)
==========================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
--------------------------------------------------------------------------
c0          2.6166      0.215     12.162      0.000       2.188       3.045
c1         -1.2340      0.249     -4.963      0.000      -1.729      -0.739
c2         -0.1215      0.265     -0.459      0.648      -0.648       0.405
==========================================================================


                     Test for Constraints  (y ~ x1 + x3)
==========================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
--------------------------------------------------------------------------
c0          2.7693      0.169     16.341      0.000       2.432       3.107
c1         -1.1637      0.234     -4.966      0.000      -1.630      -0.697
c2         -0.5462      0.256     -2.137      0.036      -1.055      -0.037
==========================================================================


                     Test for Constraints  (y ~ x1 + x5)
==========================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
--------------------------------------------------------------------------
c0          2.3491      0.186     12.638      0.000       1.979       2.719
c1         -1.2257      0.238     -5.160      0.000      -1.699      -0.753
c2          0.4067      0.277      1.467      0.147      -0.145       0.959
==========================================================================
```

```
                     Test for Constraints  (y ~ x1 + x6)
==========================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
--------------------------------------------------------------------------
c0          2.5612      0.193     13.263      0.000       2.177       2.946
c1         -1.2072      0.241     -5.008      0.000      -1.687      -0.727
c2         -0.0382      0.244     -0.156      0.876      -0.525       0.448
==========================================================================


                     Test for Constraints  (y ~ x1 + x7)
==========================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
--------------------------------------------------------------------------
c0          1.6465      0.146     11.270      0.000       1.356       1.937
c1         -0.9689      0.177     -5.462      0.000      -1.322      -0.616
c2          1.5305      0.185      8.255      0.000       1.161       1.900
==========================================================================


                     Test for Constraints  (y ~ x1 + x8)
==========================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
--------------------------------------------------------------------------
c0          1.8110      0.136     13.279      0.000       1.539       2.083
c1         -1.3174      0.179     -7.344      0.000      -1.675      -0.960
c2          1.5520      0.197      7.884      0.000       1.160       1.944
==========================================================================
```

Com isso, *x7* é selecionado e um novo modelo de regressão é gerado seguindo a fórmula $y \sim c1.x_1 + c2.x_7 + c3.x_i + c0$.

```
for i in range(1, len(data.columns)-1):
    if i != 5:
        formula = 'y ~ x1 + x7 + '+str(col[i])
        result.append(sm.OLS.from_formula(formula = formula,
data=train).fit())
        y_predicted.append(result[i-1].predict(test))
        print(formula)
        print(result[i-1].t_test(np.identity(4)))
    else:
        result.append(0)
        y_predict=0
```

O teste T de Student fica:

```
                  Test for Constraints  (y ~ x1 + x7 + x2)
==============================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
c0         1.5272      0.205      7.440      0.000       1.118       1.936
c1        -0.9249      0.186     -4.986      0.000      -1.294      -0.555
c2         1.5579      0.189      8.256      0.000       1.182       1.934
c3         0.1630      0.196      0.830      0.409      -0.228       0.554
==============================================================================


                  Test for Constraints  (y ~ x1 + x7 + x3)
==============================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
c0         1.8305      0.170     10.794      0.000       1.493       2.168
c1        -0.9465      0.174     -5.431      0.000      -1.294      -0.599
c2         1.4912      0.183      8.158      0.000       1.127       1.855
c3        -0.3828      0.189     -2.026      0.046      -0.759      -0.007
==============================================================================
```

```
                 Test for Constraints  (y ~ x1 + x7 + x5)
==================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------
c0         1.6014      0.167      9.614      0.000       1.270       1.933
c1        -0.9781      0.179     -5.468      0.000      -1.334      -0.622
c2         1.5119      0.189      7.998      0.000       1.135       1.888
c3         0.1196      0.209      0.573      0.568      -0.296       0.535
==================================================================


                 Test for Constraints  (y ~ x1 + x7 + x6)
==================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------
c0         1.7586      0.170     10.366      0.000       1.421       2.097
c1        -0.9816      0.177     -5.548      0.000      -1.334      -0.629
c2         1.5610      0.186      8.386      0.000       1.190       1.932
c3        -0.2296      0.179     -1.285      0.203      -0.586       0.126
==================================================================


                 Test for Constraints  (y ~ x1 + x7 + x8)
==================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------
c0         1.0485      0.092     11.425      0.000       0.866       1.231
c1        -1.0911      0.098    -11.158      0.000      -1.286      -0.896
c2         1.4103      0.102     13.806      0.000       1.207       1.614
c3         1.4233      0.106     13.401      0.000       1.212       1.635
==================================================================
```

Após análise, *x8* é acrescentada ao rol de preditores e a regressão é feita novamente, guiada pela fórmula $y \sim c1.x_1 + c2.x_7 + c3.x_8 + c4.x_i + c0$. O output também é alterado para uma saída estatística mais completa.

```
for i in range(1, len(data.columns)-3):
        formula = 'y ~ x1 + x7 + x8 + '+str(col[i])
        result.append(sm.OLS.from_formula(formula = formula,
data=train).fit())
        y_predicted.append(result[i-1].predict(test))
        print(formula)
        print(result[i-1].summary())
```

O output fica:

```
                            OLS Regression Results
                           (y ~ x1 + x7 + x8 + x2)
==============================================================================
Dep. Variable:                      y   R-squared:                       0.881
Model:                            OLS   Adj. R-squared:                  0.875
Method:                 Least Squares   F-statistic:                     138.9
Date:                Mon, 28 Feb 2022   Prob (F-statistic):           7.23e-34
Time:                        18:02:56   Log-Likelihood:                -5.9381
No. Observations:                  80   AIC:                             21.88
Df Residuals:                      75   BIC:                             33.79
Df Model:                           4
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept      1.0551      0.119      8.891      0.000       0.819       1.292
x1            -1.0939      0.103    -10.611      0.000      -1.299      -0.888
x7             1.4086      0.105     13.459      0.000       1.200       1.617
x8             1.4245      0.108     13.228      0.000       1.210       1.639
x2            -0.0097      0.109     -0.089      0.930      -0.227       0.208
==============================================================================
Omnibus:                        1.655   Durbin-Watson:                   2.140
Prob(Omnibus):                  0.437   Jarque-Bera (JB):                1.679
Skew:                           0.295   Prob(JB):                        0.432
Kurtosis:                       2.605   Cond. No.                         7.99
==============================================================================
```

```
                            OLS Regression Results
                          (y ~ x1 + x7 + x8 + x3)
==============================================================================
Dep. Variable:                      y   R-squared:                       0.883
Model:                            OLS   Adj. R-squared:                  0.877
Method:                 Least Squares   F-statistic:                     141.7
Date:                Mon, 28 Feb 2022   Prob (F-statistic):           3.75e-34
Time:                        18:02:56   Log-Likelihood:                -5.2367
No. Observations:                  80   AIC:                             20.47
Df Residuals:                      75   BIC:                             32.38
Df Model:                           4
Covariance Type:            nonrobust
==============================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept    1.1179      0.109     10.210      0.000       0.900       1.336
x1          -1.0819      0.098    -11.050      0.000      -1.277      -0.887
x7           1.3995      0.102     13.673      0.000       1.196       1.603
x8           1.4002      0.108     12.983      0.000       1.185       1.615
x3          -0.1241      0.107     -1.155      0.252      -0.338       0.090
==============================================================================
Omnibus:                        2.032   Durbin-Watson:                   2.063
Prob(Omnibus):                  0.362   Jarque-Bera (JB):                1.908
Skew:                           0.286   Prob(JB):                        0.385
Kurtosis:                       2.506   Cond. No.                         7.27
==============================================================================
```

```
                            OLS Regression Results
                          (y ~ x1 + x7 + x8 + x5)
==============================================================================
Dep. Variable:                      y   R-squared:                       0.881
Model:                            OLS   Adj. R-squared:                  0.875
Method:                 Least Squares   F-statistic:                     139.2
Date:                Mon, 28 Feb 2022   Prob (F-statistic):           6.68e-34
Time:                        18:02:56   Log-Likelihood:                -5.8540
No. Observations:                  80   AIC:                             21.71
Df Residuals:                      75   BIC:                             33.62
Df Model:                           4
Covariance Type:            nonrobust
==============================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept    1.0643      0.100     10.637      0.000       0.865       1.264
x1          -1.0879      0.099    -11.029      0.000      -1.284      -0.891
x7           1.4172      0.104     13.612      0.000       1.210       1.625
x8           1.4281      0.107     13.292      0.000       1.214       1.642
x5          -0.0470      0.115     -0.407      0.685      -0.277       0.183
==============================================================================
Omnibus:                        1.489   Durbin-Watson:                   2.141
Prob(Omnibus):                  0.475   Jarque-Bera (JB):                1.530
Skew:                           0.278   Prob(JB):                        0.465
Kurtosis:                       2.612   Cond. No.                         6.52
==============================================================================
```

```
                            OLS Regression Results
                          (y ~ x1 + x7 + x8 + x6)
==============================================================================
Dep. Variable:                      y   R-squared:                       0.887
Model:                            OLS   Adj. R-squared:                  0.880
Method:                 Least Squares   F-statistic:                     146.5
Date:                Mon, 28 Feb 2022   Prob (F-statistic):           1.23e-34
Time:                        18:02:56   Log-Likelihood:                -4.0458
No. Observations:                  80   AIC:                             18.09
Df Residuals:                      75   BIC:                             30.00
Df Model:                           4
Covariance Type:            nonrobust
==============================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept    1.1417      0.103     11.130      0.000       0.937       1.346
x1          -1.1007      0.096    -11.434      0.000      -1.293      -0.909
x7           1.4355      0.101     14.172      0.000       1.234       1.637
x8           1.4166      0.104     13.559      0.000       1.208       1.625
x6          -0.1849      0.097     -1.908      0.060      -0.378       0.008
==============================================================================
Omnibus:                        0.994   Durbin-Watson:                   2.090
Prob(Omnibus):                  0.608   Jarque-Bera (JB):                0.960
Skew:                           0.086   Prob(JB):                        0.619
Kurtosis:                       2.492   Cond. No.                         6.85
==============================================================================
```

Aqui, é importante notar o valor de R^2 (0,887). No próximo passo, ele será discutido. Seguindo o algoritmo, acrescenta-se *x6* e, novamente, a regressão é calculada.

```
for i in range(1, len(data.columns)-4):
        formula = 'y ~ x1 + x7 + x8 + x6 + '+str(col[i])
        result.append(sm.OLS.from_formula(formula = formula,
data=train).fit())
        y_predicted.append(result[i-1].predict(test))
        print(formula)
        print(result[i-1].summary())
```

```
                            OLS Regression Results
                        (y ~ x1 + x7 + x8 + x6 + x2)
==============================================================================
Dep. Variable:                      y   R-squared:                       0.887
Model:                            OLS   Adj. R-squared:                  0.879
Method:                 Least Squares   F-statistic:                     115.8
Date:                Mon, 28 Feb 2022   Prob (F-statistic):           1.51e-33
Time:                        18:25:54   Log-Likelihood:                -3.9884
No. Observations:                  80   AIC:                             19.98
Df Residuals:                      74   BIC:                             34.27
Df Model:                           5
Covariance Type:            nonrobust
==============================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept    1.1208     0.121      9.225      0.000       0.879       1.363
x1          -1.0911     0.101    -10.772      0.000      -1.293      -0.889
x7           1.4428     0.104     13.826      0.000       1.235       1.651
x8           1.4121     0.106     13.322      0.000       1.201       1.623
x6          -0.1919     0.100     -1.923      0.058      -0.391       0.007
x2           0.0358     0.110      0.326      0.745      -0.183       0.254
==============================================================================
Omnibus:                        1.183   Durbin-Watson:                   2.076
Prob(Omnibus):                  0.554   Jarque-Bera (JB):                1.055
Skew:                           0.080   Prob(JB):                        0.590
Kurtosis:                       2.461   Cond. No.                         8.56
==============================================================================
```

```
                            OLS Regression Results
                        (y ~ x1 + x7 + x8 + x6 + x3)
==============================================================================
Dep. Variable:                      y   R-squared:                       0.887
Model:                            OLS   Adj. R-squared:                  0.879
Method:                 Least Squares   F-statistic:                     116.2
Date:                Mon, 28 Feb 2022   Prob (F-statistic):           1.36e-33
Time:                        18:25:54   Log-Likelihood:                -3.8681
No. Observations:                  80   AIC:                             19.74
Df Residuals:                      74   BIC:                             34.03
Df Model:                           5
Covariance Type:            nonrobust
==============================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept    1.1679      0.113     10.358      0.000       0.943       1.393
x1          -1.0949      0.097    -11.261      0.000      -1.289      -0.901
x7           1.4272      0.103     13.889      0.000       1.222       1.632
x8           1.4052      0.107     13.160      0.000       1.192       1.618
x6          -0.1654      0.103     -1.605      0.113      -0.371       0.040
x3          -0.0646      0.113     -0.574      0.568      -0.289       0.160
==============================================================================
Omnibus:                        1.477   Durbin-Watson:                   2.056
Prob(Omnibus):                  0.478   Jarque-Bera (JB):                1.220
Skew:                           0.100   Prob(JB):                        0.543
Kurtosis:                       2.429   Cond. No.                         7.79
==============================================================================
```

```
                            OLS Regression Results
                        (y ~ x1 + x7 + x8 + x6 + x5)
==============================================================================
Dep. Variable:                      y   R-squared:                       0.887
Model:                            OLS   Adj. R-squared:                  0.879
Method:                 Least Squares   F-statistic:                     116.2
Date:                Mon, 28 Feb 2022   Prob (F-statistic):           1.38e-33
Time:                        18:25:54   Log-Likelihood:                -3.8893
No. Observations:                  80   AIC:                             19.78
Df Residuals:                      74   BIC:                             34.07
Df Model:                           5
Covariance Type:            nonrobust
==============================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept    1.1639      0.111     10.485      0.000       0.943       1.385
x1          -1.0968      0.097    -11.306      0.000      -1.290      -0.903
x7           1.4449      0.103     13.991      0.000       1.239       1.651
x8           1.4226      0.106     13.475      0.000       1.212       1.633
x6          -0.1883      0.098     -1.930      0.057      -0.383       0.006
x5          -0.0612      0.114     -0.539      0.592      -0.288       0.165
==============================================================================
Omnibus:                        0.938   Durbin-Watson:                   2.096
Prob(Omnibus):                  0.626   Jarque-Bera (JB):                 0.91
Skew:                           0.068   Prob(JB):                        0.633
Kurtosis:                       2.494   Cond. No.                         7.49
==============================================================================
```

É importante notar que o acréscimo de mais um preditor ao modelo não alterou o quanto a variância dos preditores explica a variância de *y*. Sendo assim, não há razão para que mais preditores sejam acrescentados ao modelo.

O próximo passo é testar as possíveis relações de sinergia. Assim, um termo x_i*x_j é acrescentado, passando por todos os preditores. A fórmula assume a forma $y \sim c1.x_1 + c2.x_7 + c3.x_8 + c4.x_6 + c5.x_i.x_j + c0$.

```
formula = 'y ~ x1 + x7 + x8 + x6 + x7*x5'
result = sm.OLS.from_formula(formula = formula, data=train).fit()
```

```
y_predicted=result.predict(test)
print(formula)
print(result.summary())
```

A fim de minimizar este relatório, os outputs irrelevantes gerados foram suprimidos. A relação que aumentou significativamente o R^2 e manteve os p-values baixos foi **x1*x3**. E está printada abaixo:

```
                            OLS Regression Results
                       (y ~ x1 + x7 + x8 + x6 + x1*x3)
==============================================================================
Dep. Variable:                      y   R-squared:                       0.900
Model:                            OLS   Adj. R-squared:                  0.892
Method:                 Least Squares   F-statistic:                     109.7
Date:                Mon, 28 Feb 2022   Prob (F-statistic):           1.74e-34
Time:                        19:05:52   Log-Likelihood:                 1.0793
No. Observations:                  80   AIC:                            11.84
Df Residuals:                      73   BIC:                            28.52
Df Model:                           6
Covariance Type:            nonrobust
==============================================================================
             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept    1.3243     0.118     11.219      0.000       1.089       1.560
x1          -1.5006     0.160     -9.380      0.000      -1.819      -1.182
x7           1.4538     0.098     14.891      0.000       1.259       1.648
x8           1.4483     0.102     14.197      0.000       1.245       1.652
x6          -0.1854     0.098     -1.896      0.062      -0.380       0.009
x3          -0.5196     0.181     -2.865      0.005      -0.881      -0.158
x1:x3        0.9807     0.316      3.100      0.003       0.350       1.611
==============================================================================
Omnibus:                        4.098   Durbin-Watson:                   2.013
Prob(Omnibus):                  0.129   Jarque-Bera (JB):                2.304
Skew:                           0.162   Prob(JB):                        0.316
Kurtosis:                       2.234   Cond. No.                         20.8
==============================================================================
```